Clasificador visual reproducible con Fashion-MNIST

Baseline denso y CNN · desempeño, costo, errores y Model Card

Universidad Autónoma de Santo Domingo · Ciencia de Datos II · Fraimel Trinidad · Prof. Edwin Ramón José Nolasco

Ejecución realizada en este proyecto. La decisión del modelo se tomó con F1 macro de validación; test se reservó para la evaluación final. Repositorio de entrega: github.com/Vic-developers/Unidad-02.-Ejercicio-04..git.

Resultado y decisión

Se selecciona **dense** por su F1 macro de validación. En test, el baseline obtuvo F1 macro 0.8605 y accuracy 0.8618; la CNN obtuvo 0.7846 y 0.7891. La CNN redujo parámetros 61.7% y tamaño 57.7%, pero tomó 5.88× más tiempo de entrenamiento y 2.06× más latencia por imagen en este equipo. Para esta corrida, la mejora de costo de almacenamiento no compensa el menor desempeño predictivo de la CNN.

Medida	Baseline denso	CNN
Accuracy (test)	0.8618	0.7891
F1 macro (test)	0.8605	0.7846
F1 macro (validación)	0.8769	0.7980
Parámetros	50,890	19,466
Tamaño	619.1 KiB	262.1 KiB
Entrenamiento	10.1 s	59.3 s
Latencia por imagen	0.295 ± 0.027 ms	0.608 ± 0.086 ms

Partición, entorno y método

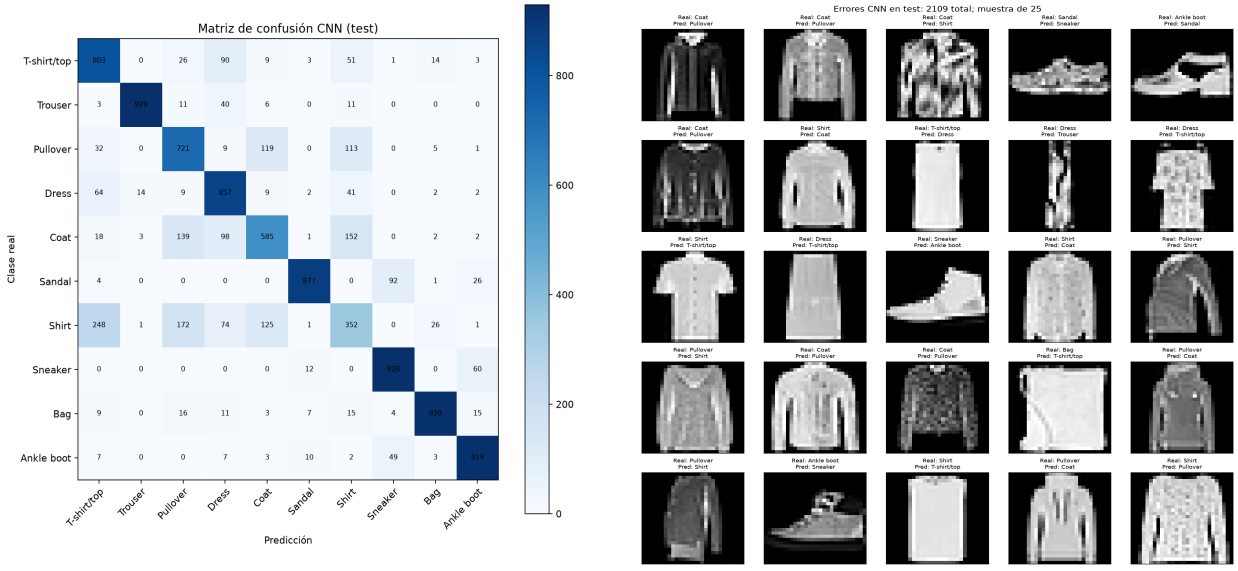
Fashion-MNIST: train 54,000, validación 6,000 y test reservado 10,000; semilla 42. Preprocesamiento `float32`, escala [0,1], forma (28, 28, 1). Ambos modelos usan Adam, entropía cruzada dispersa, lote 128 y hasta 8 épocas con early stopping por val_loss. Runtime: Python 3.12.13, TensorFlow 2.21.0, Windows-11-10.0.26300-SP0, CPU (GPU visible: no).

Desempeño por clase y errores visuales

F1 macro y recall CNN sobre test; soporte de 1,000 imágenes por clase. Los CSV del proyecto incluyen precisión, recall y F1 para ambos modelos.

Clase	Baseline F1	CNN F1	CNN recall
T-shirt/top	0.812	0.734	0.803
Trouser	0.974	0.954	0.929
Pullover	0.765	0.689	0.721
Dress	0.842	0.784	0.857
Coat	0.752	0.629	0.585
Sandal	0.955	0.917	0.877
Shirt	0.659	0.405	0.352
Sneaker	0.938	0.895	0.928
Bag	0.959	0.933	0.920
Ankle boot	0.950	0.906	0.919

La clase más difícil para la CNN fue **Shirt** (F1 0.405, recall 0.352). La mayor confusión fue Shirt → T-shirt/top (248 casos). Las imágenes son ejemplos concretos del test.



A la izquierda: matriz de confusión. A la derecha: 25 predicciones incorrectas seleccionadas por orden del conjunto test. Las similitudes visuales son interpretaciones cualitativas; la matriz no demuestra causalidad.

Alcance, IA y repositorio

Fashion-MNIST es un benchmark educativo de imágenes pequeñas, centradas y monocromas. No demuestra preparación para fotos reales, OCR, medicina, vigilancia ni decisiones sobre personas. ChatGPT/Codex apoyó el scaffold, las pruebas y la redacción; el estudiante debe revisar los resultados y añadir cualquier herramienta o prompt adicional que haya utilizado. Repositorio de entrega: Unidad-02.-Ejercicio-04..git.